

Análisis Predictivo de Lluvia en Australia

Dashboard de Minería de Datos basado en CRISP-DM

Registros analizados

142 mil

Total Registros

Tasa real de lluvia

22,42 %

Tasa Real de Lluvia

Promedio lluvia mm

2,36

Promedio lluvia mm

Accuracy en prueba

77,82 %


Accuracy Arbol Prueba

Error promedio mm


3,03

Error Promedio RISK MM

Distribución de la variable objetivo RainTomorrow



Comparación entre lluvia real y lluvia predicha



Modelo seleccionado: Árbol de Decisión

Se seleccionó por su mejor equilibrio para detectar días lluviosos, considerando Recall, F1-Score y ROC-AUC. A diferencia del Modelo Base, permite identificar correctamente casos de lluvia y ofrece un rendimiento más útil para la toma de decisiones.

Conjunto

- ☐ Seleccionar todo
- ☐ Entrenamiento
- ☐ Prueba

Location

- ☐ Adelaide
- ☐ Albany
- ☐ Albury
- ☐ AliceSprinas

Mes

1 12



Calidad y Preparación de Datos

Limpieza, transformación y validación del dataset

Registros originales

142,19 mil

Variables originales

24,00

Variables finales

106,00

Nulos finales


0,00

Registros prueba

28,44 mil

Indicador	Valor	Interpretacion
Variables originales	24	Cantidad de variables disponibles antes de la preparación.
Variables finales para modelado	106	Cantidad de variables luego de limpieza, codificación y transformación.
Valores nulos finales	0	El dataset final quedó sin valores faltantes.
Registros prueba	28439	Subconjunto utilizado para evaluación con datos no vistos.
Registros originales	142193	Cantidad total de observaciones meteorológicas analizadas.
Registros entrenamiento	113754	Subconjunto utilizado para entrenamiento de modelos.
Porcentaje prueba	20	Proporción destinada a prueba.
Porcentaje entrenamiento	80	Proporción destinada a entrenamiento.
Filas duplicadas	0	No se identificaron registros duplicados que afectaran el análisis.
Características finales X	105	Cantidad de predictores usados para entrenar los modelos.

Columnas eliminadas según criterio técnico




Proceso de Preparación de Datos

Flujo de preparación:

1. Revisión de duplicados y nulos
2. Eliminación de columnas problemáticas
3. Imputación de valores faltantes
4. Codificación de variables categóricas
5. Transformación temporal del mes
6. Tratamiento de outliers con IQR
7. Escalamiento de variables
8. División entrenamiento/prueba

Distribución entrenamiento / prueba



Justificación técnica de columnas eliminadas

Columna	Tipo_Eliminacion	Motivo	Impacto
Temp3pm	Redundancia informativa	Alta correlación con variables de temperatura conservadas.	Reduce multicolinealidad y complejidad del modelo.
Temp9am	Redundancia informativa	Alta relación con otras variables de temperatura.	Simplifica el espacio de variables sin perder información relevante.
Pressure9am	Redundancia informativa	Alta relación con Pressure3pm.	Reduce información repetida y facilita interpretación.
Cloud3pm	Valores faltantes críticos	Alto porcentaje de valores nulos.	Mejora la calidad del conjunto final y evita imputaciones poco confiables.
Cloud9am	Valores faltantes críticos	Alto porcentaje de valores nulos.	Permite trabajar con variables más completas y estables.
Evaporation	Valores faltantes críticos	Alto porcentaje de valores nulos.	Reduce ruido y evita reconstrucción artificial excesiva de datos.
Sunshine	Valores faltantes críticos	Alto porcentaje de valores nulos.	Evita imputaciones masivas que podrían distorsionar la distribución real.
Month	Transformación cíclica	El mes lineal no representa correctamente el ciclo anual.	Se reemplaza por Month_sin y Month_cos para capturar estacionalidad.
RISK_MM	Prevención de fuga de información	No debe usarse como predictor para clasificar RainTomorrow.	Evita métricas artificialmente altas y mantiene una evaluación realista.
Date	Transformación temporal	Se transformó en Month_sin y Month_cos.	Permite representar estacionalidad sin memorizar fechas específicas.

Evaluación de Modelos Predictivos y No Supervisados

Comparación de clasificación, regresión y clustering para el análisis climático

F1 clase lluvia

59,79 %

F1 Arbol

Recall lluvia

73,57 %

Recall Arbol

ROC-AUC Árbol

83,39 %

ROC AUC Arbol

R² regresión

20,58 %

R2 Regresion Prueba


Silhouette K-Means

0,292

Silhouette KMeans


Comparación de modelos de clasificación

● Accuracy ● Recall Lluvia ● F1 Lluvia ● ROC-AUC



Matriz de confusión por modelo


Tipo_Resultado ● Falso Negativo ● Falso Positivo ● Verdadero Negativo ● Verdadero Positivo




El Árbol de Decisión fue seleccionado por su mejor equilibrio entre Recall, F1-Score y ROC-AUC para detectar días lluviosos.

Evaluación de Regresión y Clustering

Tasa real vs predicha por perfil climático



Método del Codo para selección de K



Evaluación de Regresión Lineal para RISK_MM

Conjunto	MAE_mm	RMSE_mm	R2	Varianza_Explicada_%
Prueba	2,99	7,16	0,21	20,58
Entrenamiento	3,04	7,76	0,18	18,29


Evaluación de K-Means

Métrica	Valor	Interpretación
Calinski-Harabasz	66.736,80	Valores más altos indican mejor separación y compactación entre clústeres
Davies-Bouldin	1,36	Valores más bajos indican mejor calidad de agrupamiento
Silhouette Score	0,29	Rango entre -1 y 1; valores cercanos a 1 indican clústeres mejor separados


Patrones Climáticos e Insights por Ubicación

Patrones Climáticos e Insights por Ubicación


Top 10 ubicaciones con mayor precipitación promedio



Ubicaciones con mayor tasa real de lluvia




Relación entre humedad 3pm y lluvia registrada




Predicción Territorial de Lluvia

Tasa real vs tasa predicha de lluvia por ubicación



Diferencia entre tasa predicha y tasa real



Decisiones y Seguimiento del Modelo

Cierre ejecutivo del proyecto y continuidad hacia la toma de decisiones

77,82 %

Accuracy Arbol Prueba

59,79 %

F1 Arbol

73,57 %

Recall Arbol


4624

Falsos Positivos


1685

Falsos Negativos


Distribución de aciertos y errores del Árbol de Decisión



Zonas con mayor diferencia entre lluvia predicha y real



Tasa de lluvia real vs predicha por perfil climático



Prioridad de monitoreo por ubicación

Location	Suma de Registros	Lluvia real mm	Lluvia predicha mm	Tasa real %	Tasa predicha %	Promedio de Diferencia_pred_vs_real_pp	Promedio de Error_abs_promedio_RISK_MM
Adelaide	622	1,87	2,15	22,03	23,15	1,12	2,03
Albany	630	2,03	2,63	28,25	56,51	28,26	2,76
Albury	621	1,66	2,32	19,00	23,35	4,35	2,07
AliceSprings	610	1,10	1,50	8,20	7,70	-0,50	1,55
BadgerysCreek	595	2,27	2,54	21,01	27,90	6,89	2,84
Ballarat	590	1,88	2,23	25,59	43,56	17,97	2,08
Bendigo	618	1,61	1,92	18,93	23,46	4,53	1,86
Total	28439	2,33	2,74	22,16	32,48	10,32	2,99